



# 한문 고전자료 분석 사전 지식

## Pre-knowledge for the Analysis of Classical Sino-Korean Texts

민경주 ( nadopro@gmail.com )



**충남대학교 한문학과**  
Chungnam National University





## 한문 고전 자료 분석

- 데이터베이스를 이용
  - 자료를 데이터베이스에 저장
  - 질의를 통해 통계추출
  - 속도가 느림
  - 자료의 양이 방대함
- 엔그램 분석
  - 한자 사전의 한계 극복
  - 계산량이 많아짐
  - 기계학습과 같이 사전 없이 자료 만들기 가능





# 데이터베이스의 이해(삼성전자)

## • 엑셀로 이해하는 데이터베이스(삼성.xlsx)

|   | A  | B     | C      | D  | E    |
|---|----|-------|--------|----|------|
| 1 | 사번 | 이름    | 아이디    | 나이 | 입사년도 |
| 2 |    | 1 이순신 | sslee  | 34 | 2000 |
| 3 |    | 2 홍길동 | kdhong | 23 | 1989 |
| 4 |    | 3 강감찬 | gckang | 54 | 2013 |
| 5 |    | 4 홍길동 | tester | 41 | 2004 |
| 6 |    | 5 광개토 | kwang  | 30 | 2013 |
| 7 |    |       |        |    |      |
| 8 |    |       |        |    |      |

직원관리 | 급여관리 | 급여관리2 | +

3. 항목 = FIELD

1. 엑셀파일 = DB



|   | A  | B     | C      | D    |           |
|---|----|-------|--------|------|-----------|
| 1 | 순서 | 이름    | 년월     | 급여   | 설명        |
| 2 |    | 1 이순신 | 2024-1 | 1000 |           |
| 3 |    | 2 이순신 | 2024-2 | 1200 |           |
| 4 |    | 3 홍길동 | 2024-1 | 2500 | 어떤 홍길동인가? |
| 5 |    | 4 홍길동 | 2024-1 | 1300 | 어떤 홍길동인가? |
| 6 |    | 5 강감찬 | 2024-1 | 1200 |           |
| 7 |    | 6 강감찬 | 2024-2 | 1250 |           |
| 8 |    | 7 광개토 | 2024-1 | 1700 |           |

직원관리 | 급여관리 | 급여관리2 | +

2. Sheet = TABLE

4. 데이터 = ROW, RECORD

|   | A  | B     | C      | D      | E    | F        |
|---|----|-------|--------|--------|------|----------|
| 1 | 순서 | 이름    | 아이디    | 년월     | 급여   | 설명       |
| 2 |    | 1 이순신 | sslee  | 2024-1 | 1000 |          |
| 3 |    | 2 이순신 | sslee  | 2024-2 | 1200 |          |
| 4 |    | 3 홍길동 | kdhong | 2024-1 | 2500 | 홍길동이 구분됨 |
| 5 |    | 4 홍길동 | tester | 2024-1 | 1300 | 홍길동이 구분됨 |
| 6 |    | 5 강감찬 | gckang | 2024-1 | 1200 |          |
| 7 |    | 6 강감찬 | gckang | 2024-2 | 1250 |          |
| 8 |    | 7 광개토 | kwang  | 2024-1 | 1700 |          |

직원관리 | 급여관리 | 급여관리2 | +



# 데이터베이스의 이해

- 엑셀로 이해하는 데이터베이스
- 데이터베이스를 사용하는 순서
  - 1. 데이터베이스를 만든다(엑셀파일)
    - Sheet가 없는 엑셀파일
  - 2. 테이블을 원하는 만큼 만든다.(Sheet)
    - 항목은 사용자가 정한다.
  - 3. 데이터를 넣는다.
  - 4. 원하는 데이터를 처리한다.
    - 검색, 합 구하기, 통계, 삭제, 추가, 변경



# 데이터베이스의 이해(충남대학교)

|   | A  | B  | C  | D           | E  | F    |
|---|----|----|----|-------------|----|------|
| 1 | 순서 | 사번 | 이름 | 아이디         | 나이 | 입사년도 |
| 2 | 5  | 1  | 한문 | sino-korean | 28 | 2021 |
| 3 | 10 | 2  | 국문 | korean      | 22 | 2022 |
| 4 | 15 | 3  | 영문 | english     | 42 | 2020 |
| 5 | 20 | 4  | 언어 | language    | 32 | 2022 |
| 6 | 25 | 5  | 일문 | japan       | 37 | 2021 |
| 7 |    |    |    |             |    |      |

키(Key)

| 1 | 순서 | 고유번호 | 년월     | 급여   |
|---|----|------|--------|------|
| 2 | 1  | 5    | 2024-1 | 1000 |
| 3 | 2  | 5    | 2024-2 | 1200 |
| 4 | 3  | 20   | 2024-1 | 2500 |
| 5 | 4  | 15   | 2024-1 | 1300 |
| 6 | 5  | 25   | 2024-1 | 1200 |
| 7 | 6  | 25   | 2024-2 | 1250 |
| 8 | 7  | 10   | 2024-1 | 1700 |

충남대학교 한문학과 - 디지털콘텐츠개론 ( nadopro@gmail.com )





# 데이터베이스의 이해(MySql, MariaDB) :DBMS

| 1 | 순서 | 데이터베이스  | 사용자    | 비밀번호 | 권한          |
|---|----|---------|--------|------|-------------|
| 2 | 1  | samsung | test   | 1111 | 검색/삽입/수정/삭제 |
| 3 | 2  | samsung | guest1 | 1234 | 검색          |
| 4 | 3  | cnu     | sino   | 2222 | 검색/삽입/수정/삭제 |
| 5 | 4  | cnu     | korean | 2223 | 검색/수정       |
| 6 | 4  | kakao   | daum   | 3333 | 검색/삽입/수정/삭제 |
| 7 |    |         |        |      |             |

데이터베이스 접속정보 (+)



| 1 | 순서 | 데이터베이스  | 호스트       |
|---|----|---------|-----------|
| 2 | 1  | samsung | localhost |
| 3 | 2  | cnu     | *         |
| 4 | 3  | kakao   | localhost |
| 5 |    |         |           |

데이터베이스 접속정보 (+)

# DBMS : DB Management System

- DBMS
  - 데이터베이스(엑셀)를 관리하는 데이터베이스
  - 보안
- DBMS의 종류
  - Oracle
  - MySQL
    - MariaDB
  - MSSQL
  - 메모리 DB : H2DB



# 데이터베이스

- 데이터베이스

- 검색, 삽입, 삭제, 갱신을 빠르게 하도록 설계된 특별한 형태의 파일 시스템 → 일반 파일에 비해 빠르지만, 근본적으로 느림
- 한문 고전 데이터 처리
  - 한국고전종합DB 등에는 유용
  - 빠른 분석에는 효율적이지 않음.



# 엔그램 분석

K

당신

엔그램 분석에 대해 설명해 줘.

ChatGPT

ChatGPT

엔그램(Engram) 분석은 텍스트 데이터에서 연속적으로 발생하는 문자열이나 단어의 묶음을 분석하는 기법입니다. 이 방법은 언어 처리, 텍스트 마이닝, 정보 검색 등 다양한 분야에서 사용됩니다.

엔그램은 주어진 시퀀스(예: 문장) 내에서  $n$ 개의 연속적인 아이템(예: 글자, 단어)으로 구성됩니다. 예를 들어, "hello"라는 단어에서 2-gram(또는 바이그램)을 추출하면 "he", "el", "ll", "lo"가 됩니다. 만약 3-gram(또는 트라이그램)을 추출한다면 "hel", "ell", "llo"가 됩니다.

엔그램 분석은 다음과 같은 목적으로 사용될 수 있습니다:


1. **텍스트 패턴 인식:** 텍스트 내에서 반복되는 패턴이나 표현을 찾아낼 수 있습니다. 예를 들어, 어떤 단어나 구절이 자주 등장하는지 파악할 수 있습니다.
2. **언어 모델링:** 언어의 확률적 모델을 생성하기 위해 사용됩니다. 이는 자연어 처리(NLP)에서 중요한 역할을 하며, 기계 번역, 음성 인식 등에 사용됩니다.
3. **문서 분류 및 클러스터링:** 특정 텍스트가 어떤 주제에 속하는지 분류하거나, 유사한 문서끼리 묶는 데 사용됩니다.
4. **스팸 필터링:** 이메일이나 메시지의 내용을 분석하여 스팸 여부를 판단하는 데 도움을 줍니다.

엔그램 분석은 자연어 처리의 기본적인 도구 중 하나로, 단순하지만 효과적인 방법으로 다양한 텍스트 관련 문제를 해결하는 데 도움을 줍니다.

com )

## 엔그램 분석

- N-gram 분석
  - 글자를 N음절씩 쪼개 출현 빈도 분석하는 방법
  - 명칭(한문학과)
    - 1-gram(uni-gram) : 한, 문, 학, 과 → 총 4개
    - 2-gram(bi-gram) : 한문, 문학, 학과 → 총 3개
    - 3-gram(tri-gram) : 한문학, 문학과 → 총 2개
    - 4-gram : 한문학과 → 총 1개
    - 5-gram : ( 없음 ) → 0개
    - 6-gram : ( 없음 ) → 0개





## 엔그램 분석

- 한문학과
- 일어일문학과
- 언어학과
- 철학과

| # | 1음절 | 2음절  | 3음절   |
|---|-----|------|-------|
| 1 | 학 4 | 학과 4 | 문학과 2 |
| 2 | 과 4 | 문학 2 | -     |
| 3 | 문 2 | -    | -     |
| 4 | 일 2 | -    | -     |
| 5 | 어 2 | -    | -     |



- [illegible]



## 엔그램 분석

- 어휘의 출현 빈도 파악
  - 사전화가 어려운 한문 자료에 적합
  - 출현빈도에서 전체적인 맥락 파악의 가능성
  - 허사의 확장 이해에 도움 → 한문법, 연결어 파악
- 단점
  - 불필요한 결과물이 많을 수 있다.
- 활용
  - 학습을 통한 어휘 사전
  - 실제 사전과 다른 쓰임새 파악



# 엔그램 분석을 위한 프로그래밍

```

7  <div class="container">
8      <div class="row">
9          <div class="col colline text-primary">
10             <span class="material-icons">analytics</span> 엔그램 분석
11          </div>
12      </div>
13
14      <form method="post" action="dc38.php"> <!-- 현재 파일 -->
15      <div class="row">
16          <div class="col colline">
17              <textarea name="text" class="form-control" rows="5">충남대학교 한문학과</textarea>
18          </div>
19      </div>
20      <div class="row">
21          <div class="col colline text-center">
22              <button type="submit" class="btn btn-primary btn-sm">분석</button>
23          </div>
24      </div>
25      </form>
26
27      <div class="row">
28          <div class="col colline">
29              분석하는 곳<br>
30          </div>
31      </div>
32  </div>
33
34  <!-- 계속 추가 되는 영역 -->
35  </div> <!-- container 표시해 놓으면 구분하기 쉬워진다. -->
    
```

무엇을 해야 하는가?



# 충남대학교 한문학과 ← 띄어쓰기 단위로 분리

- \$\_GET["이름"] , \$\_POST["이름"]

```

27      <div class="row">
28          <div class="col colLine">
29              분석하는 곳<br>
30
31              <?php
32                  if(isset($_POST["text"]))
33                  {
34                      echo "POST로 text가 왔으니까, 분석하라!!!";
35                  }else
36                  {
37                      echo "분석 아님 .. 첫화면";
38                  }
39              ?>
40
41          </div>
42      </div>

```

isset() : 값이 채워져 있느냐?  
\$\_POST["text"] : POST로 넘어온 text라는 이름

엔그렘 분석

충남대학교 한문학과

분석하는 곳

분석 아님 .. 첫화면

분석

엔그렘 분석

충남대학교 한문학과

분석

분석하는 곳

POST로 text가 왔으니까, 분석하라!!!



</div> <!-- container 표시해 놓으면 구분하기 쉬워진다. -->

가은 문제

엔그램

충남대학교 한문학과

분석

분석하는 곳

POST로 text가 왔으니까, 분석하라!!!

0: 충남대학교

1: 한문학과

2: 디지털

3: 콘텐츠

4: 개론

## 화면과 분석 결과 일치

### • 화면 결과를 일치 시키자

POST로 넘어온 값 있으면 \$text에 저장  
없으면 기본값 설정

```
14 <?php
15     if(isset($_POST["text"]))
16     {
17         $text = $_POST["text"];
18     }else
19     {
20         $text = "충남대학교 인문대학 한문학과 디지털 콘텐츠 개론";
21     }
22 >?>
23
24 <form method="post" action="dc38.php"> <!-- 현재 파일 -->
25 <div class="row">
26     <div class="col colline">
27         <textarea name="text" class="form-control" rows="5"><?php echo $text ?></textarea>
28     </div>
29 </div>
30 <div class="row">
31     <div class="col colline text-center">
32         <button type="submit" class="btn btn-primary btn-sm">분석</button>
33     </div>
34 </div>
35 </form>
```

설정값(\$text)으로  
화면 설정



## 코드 가독성을 위한 임시 변경

```
37         <div class="row">
38             <div class="col colline">
39                 분석하는 곳<br>
40 <!-- Shift-Tab 4번 시작 : 완성되면 탭 4번 -->
41 <?php
42     ... if(isset($_POST["text"]))
43     ... {
44     ...     echo "POST로 text가 왔으니까, 분석하라!!!<br>";
45
46     ...     $myData = explode(" ", $_POST["text"]);
47     ...     $dataCount = count($myData);
48     ...     for($i = 0; $i < $dataCount; $i++)
49     ...     {
50     ...         echo "$i : $myData[$i] <br>";
51     ...     }
52     ... }else
53     ... {
54     ...     echo "분석 아님 ... 첫화면<br>";
55     ... }
56 ?>
57 <!-- Shift-Tab 4번 끝 -->
58     </div>
59 </div>
```

충남대학교 한문학과 - 디지털콘텐츠개론 ( nadopro@gmail.com )

# 각 문자열 길이와 글자수 확인

```

41 <?php
42     if(isset($_POST["text"]))
43     {
44         echo "POST로 text가 왔으니까, 분석하라!!!<br>";
45
46         $myData = explode(" ", $_POST["text"]);
47         $dataCount = count($myData);
48         for($i = 0; $i < $dataCount ; $i++)
49         {
50             $len = strlen($myData[$i]);
51             $chars = mb_strlen($myData[$i]);
52             echo "$i : $myData[$i] : $len vs. $chars <br>";
53         }
54     }else
55     {
56         echo "분석 아님 .. 첫화면<br>";
57     }
58 ?>

```

글자수를 셀 때는  
mb\_strlen(문자열)

분석하는 곳  
POST로 text가 왔으니까, 분석하라!!!  
0 : 충남대학교 : 15 vs. 5  
1 : 인문대학 : 12 vs. 4  
2 : 한문학과 : 12 vs. 4  
3 : 디지털 : 9 vs. 3  
4 : 콘텐츠 : 9 vs. 3  
5 : 개론 : 6 vs. 2

충남대학교 한문학과 - 디지털콘텐츠개론 ( nadopro@gmail.com )

# 분리된 단어(words)별 N그램 구분

```

40 <?php
41     if(isset($_POST["text"]))
42     {
43         $myData = explode(" ", $_POST["text"]);
44         $dataCount = count($myData);
45         for($words = 0; $words < $dataCount ; $words++)
46         {
47             $chars = mb_strlen($myData[$words]);
48             echo "$words : $myData[$words] > $chars 글자 <br>";
49
50             // n-gram 분리
51             for($gram = 1; $gram <= $chars; $gram++)
52             {
53                 echo "$gram gram 분석 <br>";
54             }
55         }
56     }else
57     {
58         echo "입력란에 문장을 넣고 분석 버튼을 클릭하세요.<br>";
59     }
60 ?>

```

의미를 쉽게 \$i를  
\$word로 변경함

0 : 충남대학교 > 5 글자  
1 gram 분석  
2 gram 분석  
3 gram 분석  
4 gram 분석  
5 gram 분석  
1 : 인문대학 > 4 글자  
1 gram 분석  
2 gram 분석  
3 gram 분석  
4 gram 분석  
2 : 한문학과 > 4 글자  
1 gram 분석



# 분리된 단어(words)별 N그램 구분

```

40 <?php
41     if(isset($_POST["text"]))
42     {
43         $myData = explode(" ", $_POST["text"]);
44         $dataCount = count($myData);
45         for($words = 0; $words < $dataCount ; $words++)
46         {
47             $chars = mb_strlen($myData[$words]);
48             echo "$words : $myData[$words] > $chars 글자 <br>";
49
50             // n-gram 분리
51             for($gram = 1; $gram <= $chars; $gram ++){
52                 echo "$gram gram 분석 <br>";
53                 for($pos = 0; $pos <= $chars; $pos ++){
54                     {
55                         $subText = mb_substr($myData[$words], $pos, $gram);
56                         echo "$subText<br>";
57                     }
58                 }
59             }
60         }
61     }else
62     {
63         echo "입력란에 문장을 넣고 분석 버튼을 클릭하세요.<br>";
64     }
65 ?>

```

0 : 충남대학교 > 5 글자  
1 gram 분석  
충  
남  
대  
학  
교  
2 gram 분석  
충남  
남대  
대학  
학교  
그

mb\_substr(대상, 위치, 글자수)

4-gram에서 뒤쪽 오류  
제외해야 함

3 gram 분석  
충남대  
남대학  
대학교  
학교  
교  
4 gram 분석  
충남대학  
남대학교  
대학교  
학교  
교  
5 gram 분석



```

40 <?php
41     if(isset($_POST["text"]))
42     {
43         $myData = explode(" ", $_POST["text"]);
44         $dataCount = count($myData);
45         for($words = 0; $words < $dataCount ; $words++)
46         {
47             $chars = mb_strlen($myData[$words]);
48             echo "$words : $myData[$words] > $chars 글자 <br>";
49
50             // n-gram 분리
51             for($gram = 1; $gram <= $chars; $gram ++ )
52             {
53                 echo "$gram gram 분석 <br>";
54                 for($pos = 0; $pos <= $chars; $pos ++ )
55                 {
56                     if($pos + $gram <= $chars)
57                     {
58                         $subText = mb_substr($myData[$words], $pos, $gram);
59                         echo "$subText<br>";
60                     }else
61                     {
62                         break; // 나를 둘러싼 첫번째 반복문을 빠져나가기
63                     }
64                 }
65             }
66         }
67     }else
68     {
69         echo "입력란에 문장을 넣고 분석 버튼을 클릭하세요.<br>";
70     }
71 ?>
72 <!-- Shift-Tab 4번 끝 -->
73     <br><br><br><br>

```

현재위치 + gram이  
글자수보다 작을 때만

현재위치 + gram이  
글자수보다 크면 그만!!


# 충남대학교 인문대학 한문학과 디지털 콘텐츠 개론



# 글자별 저장하기 : 배열(Array)

- 배열의 개념
  - 여러 개의 변수를 묶어서 관리
  - 인덱스는 0번부터 시작
    - 4글자 저장 : [0] ~ [3]
    - 반복문으로 빠르게 처리

|   |        |
|---|--------|
| 한 | str[0] |
| 문 | str[1] |
| 학 | str[2] |
| 과 | str[3] |






# 글자별 저장하기 : 연관배열(Associative Array)

## • 연관 배열

- 인덱스 대신 문자열 사용하는 배열
- 사전 데이터에 유용
  - dict["cnu"] = 충남대학교
  - dict["humanities"] = 인문대학
  - 이해가 쉽다




|       |                    |
|-------|--------------------|
| 충남대학교 | dict["cnu"]        |
| 인문대학  | dict["humanities"] |
| 한문학과  | dict["sinokorean"] |
| 디지털   | dict["digital"]    |

## 2차원 배열

- 자료가 많을 때 격자 모양으로 배열 구성

- 다음의 형태도 가능
- `dict[0]["cnu"]`
- `dict["humanities"][3]`



|            |            |            |            |            |            |
|------------|------------|------------|------------|------------|------------|
| dict[0][0] | dict[0][1] | dict[0][2] | dict[0][3] | dict[0][4] |            |
| 충          | 남          | 대          | 학          | 교          |            |
| 충남         | 남대         | 대학         | 학교         | 인문         |            |
| 충남대        | 인문대학       | 한문학과       | 디지털        | 콘텐츠        | dict[1][4] |
| dict[2][0] |            | dict[2][2] |            | dict[2][4] |            |

```

40 <?php
41     if(isset($_POST["text"]))
42     {
43         $wordArray = array(); // $wordArray를 사용하겠다.
44
45         $myData = explode(" ", $_POST["text"]);
46         $dataCount = count($myData);
47         for($words = 0; $words < $dataCount ; $words++)
48         {
49             $chars = mb_strlen($myData[$words]);
50             echo "$words : $myData[$words] > $chars 글자 <br>";
51
52             // n-gram 분리
53             for($gram = 1; $gram <= $chars; $gram ++ )
54             {
55                 echo "$gram gram 분석 <br>";
56                 for($pos = 0; $pos <= $chars; $pos ++ )
57                 {
58                     if($pos + $gram <= $chars)
59                     {
60                         $subText = mb_substr($myData[$words], $pos, $gram);
61
62                         if(isset($wordArray[$subText]))
63                         { // 해당 문자열이 있으면 숫자 증가
64                             $wordArray[$subText] ++;
65                         }
66                         else
67                         { // 해당 문자열이 없으면 1
68                             $wordArray[$subText] = 1;
69                         }
70                         echo "$subText : $wordArray[$subText] <br>";
71                     }
72                     else
73                     {
74                         break; // 나를 둘러싼 첫번째 반복문을 빠져나가기

```



충

남

대

학

교

한

문

학

과





## 음절 정보를 포함한 2차원 배열

```

52 // n-gram 분리
53 for($gram = 1; $gram <= $chars; $gram++)
54 {
55     echo "$gram gram 분석 <br>";
56     for($pos = 0; $pos <= $chars; $pos++)
57     {
58         if($pos + $gram <= $chars)
59         {
60             $subText = mb_substr($myData[$words], $pos, $gram);
61
62             if(isset($wordArray[$subText]))
63             { // 해당 문자열이 있으면 숫자 증가, 첫째 인덱스에 글자수
64                 $wordArray[mb_strlen($subText)][$subText]++;
65             }
66             else
67             { // 해당 문자열이 없으면 1, 첫째 인덱스에 글자수
68                 $wordArray[mb_strlen($subText)][$subText] = 1;
69             }
70             echo "$subText : ". $wordArray[mb_strlen($subText)][$subText] . "<br>";
71         }
72         else
73         {
74             break; // 나를 둘러싼 첫번째 반복문을 빠져나가기
75         }
76     }
77 }

```

## • 최대 음절 찾기

```

40 <?php
41     if(isset($_POST["text"]))
42     {
43         $wordArray = array(); // $wordArray를 사용하겠다.
44         $maxSyllable = 0;
45
46         $myData = explode(" ", $_POST["text"]);
47         $dataCount = count($myData);
48         for($words = 0; $words < $dataCount ; $words++)
49         {
50             $chars = mb_strlen($myData[$words]);
51             echo "$words : $myData[$words] > $chars 글자 <br>";
52
53             if($chars >= $maxSyllable) // 내용이 한 줄인 경우 { } 생략 가능
54             {
55                 $maxSyllable = $chars;
56             }
57
58             // n-gram 분리
59             for($gram = 1; $gram <= $chars; $gram++)
60             { ...
82             }
83         }
84
85         for($syllable = 1; $syllable <= $maxSyllable; $syllable++)
86         {
87             echo "$syllable 음절어 <br>";
88         }
89     }else
90     {
91         echo "입력란에 문장을 넣고 분석 버튼을 클릭하세요.<br>";
92     }
93 }>

```

2 gram 분석  
 개론 : 1  
 1 음절어  
 2 음절어  
 3 음절어  
 4 음절어  
 5 음절어



## 출력의 문제

- 배열의 정확한 이름을 알 수 없음.
  - 예: wordArray[1]["한"] ← 여기서 "한" 을 알 수 없는 문제
  - 대략적인 알고리즘
- ➔ 현재 음절의 모든 데이터를 순서대로 다 가져오기

```
85     for($syllable = 1; $syllable <= $maxSyllable; $syllable ++)  
86     {  
87         echo "$syllable 음절어 <br>";  
88         arsort($wordArray[$syllable]); // 오름차순은 asort()  
89         $count = count($wordArray[$syllable]); // 현재 음절의 데이터 수  
90         echo "count = $count <br>";  
91  
92         for($i = 0; $i < $count; $i++)  
93         {  
94             // 어떤글자가 몇 번 있는지 출력  
95             // 어떻게 알지?  
96             echo "$wordArray[$syllable][??] : $wordArray[$syllable][??]";  
97         }  
98     }
```

## 결과 출력

```

85 // 결과 출력
86 for($syllable = 1; $syllable <= $maxSyllable; $syllable++)
87 {
88     echo "$syllable 음절어 <br>";
89     arsort($wordArray[$syllable]); // 오름차순은 asort()
90
91     foreach($wordArray[$syllable] as $key => $value)
92     {
93         echo "$key : $value <br>";
94     }
95 }

```

1 음절어  
 학 : 3  
 대 : 2  
 문 : 2  
 충 : 1  
 털 : 1  
 개 : 1  
 츠 : 1  
 텐 : 1  
 콘 : 1  
 과 : 1  
 지 : 1  
 디 : 1  
 남 : 1  
 한 : 1  
 인 : 1  
 교 : 1  
 룬 : 1  
 2 음절어  
 대학 : 2  
 충남 : 1

- 프로그램이 완성될 때까지
  - 불필요한 화면 출력 내용은 그대로!!
  - 현재까지의 파일을 복사해 하나 더 만들기 ➔ 한문고전

# 운양집 내용 복사(答人論青邱文章源流)

## 엔그램 분석

a328\_626d 客有過余者。歎世之將無讀書種子。因縱言至於文章之學曰。我東文章。隨時汚隆。今文苑長老。零落殆盡。後生無以述焉。子能詳言其源流乎。余應之曰。僕少時頗攻文藝。然得於口耳之餘。非有深造。今昏耄已甚。何敢論古今人長短乎。蓋嘗聞諸先輩緒言。在昔三國中葉以後。公用文字。皆仿文選。如任強首。崔文昌其顯者也。至麗初猶然。而若名臣章奏及碑版之作。往往有兩漢氣味。非後世可及。及其季也。益齋。稼亭。牧隱諸公。倡爲古文辭。大鳴於世。繼以陽村。春亭。一變駢儷之舊。其後佔俾。乖匡。四佳。虛白。以大家 a328\_627a 稱。而張新豐序簡易齋集云虛白。四佳。通敏利用。館閣之豪。乖匡博而寡法。佔俾精而未大。右文之化。極於宣廟。而簡易爲稱首。其文寧晦而毋或淺。寧澁而毋或凡。截長續短。可與乖匡佔俾鼎立。是時又有象村。月沙。溪谷。澤堂。世稱爲象月溪澤。象村之文。鎔鍊淘洗。有明末清初文氣。月沙之文。不以彫彩爲工。行文馴熟。盡其所欲言而止。論者又云溪谷天才優。澤堂人工勝。蓋各有其所長也。農巖之文。學理醇深。息庵之文。氣力雄渾。與溪澤并稱。藥泉。明谷。奏議明邕。時稱館閣之才。英廟時雷淵。晉庵。月谷。江漢諸 a328\_627b 公。迭主文盟。而尤推江漢爲大手筆。其文典雅高古。長於史才。可與古作者爭一席。近世作家。推淵泉。臺山。淵泉之文。步趨有度。不越乎矩矱之外。而紆餘春容。感激而不傷。洵爲治世之文。臺山之文。掇百氏之英。融爲一家。俯仰有致。風神翛然。繼此以往。寥寥未有聞也。蓋自麗末群賢。宗性理之學。爲文而無學問根據者。人病其無實而不取也。是以操觚之士。未嘗有涵養研索之工。而開口便談性命。掇拾宋賢書牘。以自潤其文。此亦文之一病也。能脫此病者。其惟燕巖乎。燕巖之文。如天馬行空。不施羈勒。而自然中節。 a328\_627c 此可謂文中之龍。後生不可學得者也。大略如此。不可縷述。夫觀止於韶。譏不及郢。卽此可以觀世之汙隆矣。客唯唯而退。

분석

- 페이지를 지울 것인가?
- 프로그램으로 지울 것인가?



## 한문 고전 분석할 때 고려사항

- 문장의 구분은 구두점(。)
- 한글은 마침표(.)와 공백으로 분석
 

其後佔僂，乖厓，四佳，虛白。以大家<sup>P</sup>稱。
- 콤마(,)로 구분되는 경우는 공백으로 바꾸기
- 구두점 (。 ) 을 공백으로 바꾸기
- 쪽 표시 제거
  - a328\_626d a328\_627a a328\_627b a328\_627c 등
- 영문, 한글, 숫자, 결락 표시(■) 등 제거
  - 조선말기 한글편지 등은 고려하지 않음



## 불필요한 문장기호 제거

- 위쪽 action="현재파일명" 변경
- action을 그대로 쓰면 컴퓨터 다운될 수 있음.

```

40 <?php
41     if(isset($_POST["text"]))
42     {
43         $wordArray = array(); // $wordArray를 사용하겠다.
44         $maxSyllable = 0;
45
46         // 여기서 불필요한 문장 기호 제거
47         $doc = preg_replace("/[a-zA-Z0-9_\s]+/", "", $_POST["text"]);
48         $doc = preg_replace("/[o. ? , ,&·《》〈〉· ! : ()]/u", "", $doc);
49         $doc = preg_replace("/[\s]+/", " ", $doc);
50
51         $myData = explode(" ", $doc);
52         $dataCount = count($myData);
53         for($words = 0; $words < $dataCount ; $words++)
54         {

```

/u에서 u는 유니코드를 의미함!!



## One More Thing!!!

충남대학교

```
90 // 결과 출력
91 echo "
92 <table class='table table-bordered'>";
93     for($i = 1; $i<=30; $i++)
94     {
95         echo "
96         <tr>
97             <td># $i</td>";
98         for($n = 1; $n<=5; $n++)
99         {
100             arsort($wordArray[$n]);
101             $tmp = 0;
102             foreach($wordArray[$n] as $key => $value)
103             {
104                 if($tmp < $i - 1)
105                 { // do nothing
106                 }else
107                 {
108                     if($value <=1)
109                     {
110                         echo "<td>-</td>";
111                     }
112                     else
113                     {
114                         echo "<td>$key</td>";
115                         echo "<td>$value</td>";
116                     }
117                     break;
118                 }
119                 $tmp ++;
120             }
121             echo "</tr>";
122         }
123     }
124     echo "
125     </table>";
```



충

남

대

학

교

한

문

학

과


# 표 형태로 보이기(표는 엑셀로 변환 가능)

5 gram 분석

客唯唯而退 : 1

125 : > 0 글자

|      |   |    |    |   |     |   |   |   |
|------|---|----|----|---|-----|---|---|---|
| # 1  | 文 | 26 | 之文 | 8 | 而母或 | 2 | - | - |
| # 2  | 之 | 25 | 其文 | 3 | 巖之文 | 2 | - | - |
| # 3  | 而 | 16 | 佔傳 | 3 | -   | - | - | - |
| # 4  | 其 | 11 | 其文 | 3 | -   | - | - | - |
| # 5  | 有 | 10 | 佔傳 | 3 | -   | - | - | - |
| # 6  | 以 | 9  | 閣之 | 2 | -   | - | - | - |
| # 7  | 爲 | 8  | 者也 | 2 | -   | - | - | - |
| # 8  | 不 | 8  | 可與 | 2 | -   | - | - | - |
| # 9  | 也 | 7  | 簡易 | 2 | -   | - | - | - |
| # 10 | 者 | 7  | 可與 | 2 | -   | - | - | - |
| # 11 | 世 | 7  | 後生 | 2 | -   | - | - | - |
| # 12 | 可 | 7  | 文之 | 2 | -   | - | - | - |
| # 13 | 此 | 6  | 澤堂 | 2 | -   | - | - | - |



충남대학교 한문학과 - 디지털콘텐츠개론 ( nadopro@gmail.com )